EINFÜHRUNG IN DAS MASCHINELLE LERNEN – L1

EXPLORATORISCHE DATENANALYSE MIT PANDAS

Bekommen in L1

Abgabe in L2

Vergewissere dich, dass du auf deiner Maschine Python, Version mindestens 3.11, eine IDE mit Jupyter Notebooks (z.B. VSCode mit den passenden Extensions), und die Bibliotheken pandas, matplotlib und sklearn, hast. Alternativ für Plots, auch seaborn.

Optional, aber nützlich als "good practice": erstelle ein virtuelles Environment für deine Projekte. Dies hilft sicherzustellen, dass alle Abhängigkeiten und Bibliotheken die richtige Version haben. Benutze zum Management der Pakete eine Software wie z.B. poetry. Dies stellt sicher, dass für alle Pakete die Versionen kompatibel sind, sowie dass verschiedene Anwendungen und ihre Abhängigkeiten nicht in Konflikt geraten. Dies ist Standardpraxis für große Projekte in der Industrie, denn verschiedene Projekte können verschiedene Versionen von Bibliotheken benutzen. Siehe hier ein Tutorial darüber. Es wird empfohlen, auch ein Linter, z.B. die pylint-Extension aus VSCode zu installieren.

Das Ames Housing Dataset wird häufig als Benchmark-Datensatz für Data Science Experimente benutzt. Erstelle ein Jupyter Notebook, wo du mithilfe der Pandas-Bibliothek die vorgegebene csv-Datei einliest.

Untersuche den Datenset. Denke an Outliers, fehlende Daten, usw. Zeichne insgesamt mindestens 10 Plots, von verschiedenen Arten, die **unterschiedliche** sinnvolle Fragestellungen beantworten können: Histogramme, Scatter Plots, Box Plots, Violin Plots, usw. **Zeichne mindestens ein Heatmap.** Denke z.B. an die Verteilung der Werte. Identifiziere numerische, bzw. kategorische Features. Denke auch an mögliche Verbindungen zwischen Features. Interpretiere die Ergebnisse. Folgende Funktionen aus Pandas oder Matplotlib könnten nutzlich sein: isnull, isna, value_counts, describe, head, mean, min, max, groupby, scatter, hist, corr…

Beispiel: wenn man in einer Notebook-zelle housing[housing["Lot Area"] > 40000], dann werden alle Anwesen mit der betreffenden Eigenschaft angezeigt. Man kann auch komplexere Filter anlegen. Pandas hat Funktionalitäten ähnlich dem join, bzw. groupby aus SQL, die Syntax kann aber verschieden sein.

Mit was für Daten von außen könnte man das Dataset bereichern? Welche vorhandenen Features kann man als Kandidaten für Entfernung sehen? Was für zusätzliche sinnvolle Features kann man aus Kombinationen der gegebenen Features erzeugen? Begründe.

Bonus: Finde zwei Paare von Features, zwischen denen eine lineare Relation existieren könnte. Hinweis: Benutze dafür Scatter Plots. Denk nach, warum diese Verbindung existiert. Kann das eine tatsächliche Korrelation sein oder nicht (spurious correlations)? Implementiere eine lineare Regression auf die so gefundenen Features. Siehe hier (sklearn dokumentation). Zeichne die Regressionsgerade und die Punkte mit verschiedenen Farben. Vergleiche den tatsächlichen mit dem vorhergesagten Wert für einige Punkte aus dem Datenset und für einige sinnvolle Punkte.

Wichtiger Hinweis: Die nächsten Laboraufgaben beziehen sich auf demselben Datensatz: Prädiktion (Aufgabe 2), bzw. Clustering (Aufgabe 3). Ein tiefes Verständnis der Zusammenhänge, und ein Nachdenken an möglichen Features für Modelle schon bei dieser Aufgabe kann sehr hilfreich sein.