GRUNDLAGEN DES MASCHINELLEN LERNENS – L2

KLASSIFIKATION MIT XGBOOST

Erhalten in L2

Abgabe in L3

Installiere die xgboost und optuna Bibliotheken. Um sicherzustellen, dass alles im Notebook funktioniert:

```
pip install xgboost plotly optuna anywidget
```

Benutze das bereinigte Ames Housing Dataset, mit passendem Encoding für kategorische Features (Aufgabe 1). Implementiere xgboost als Multiclass-Classifier, um die Preise der Wohnungen vorherzusagen. Benutze folgende sechs Klassen: Preis <100000; 100000 – 130000; 130000 – 180000; 180000 – 250000; 250000 – 400000; >=400000.

Für alle Experimente: Denke auch an stratification und versuche es mit und ohne. Benutze train-test-split 10%, bzw. 20% und vergleiche die Ergebnisse. Benutze k-fold cross validation. Benutze k=5 und k=10. Interpretiere das Ergebnis. Berücksichtige auch den bias-variance tradeoff.

Zeichne den ersten und den besten Baum, und die Feature Importance (gain und split). Mehr Details dazu in der Dokumentation. Präsentiere die Metriken precision, accuracy, recall, f1. Zeichne auch die Konfusionsmatrix, die ROC-Kurve und die Precision-Recall-Kurve, und finde die precision-recall Schwellen, welche dem besten macro-f1 entsprechen. Interpretiere die Ergebnisse.

Vergleiche die Ergebnisse für verschiedene Datenvorbereitungsstrategien. Bei Bedarf experimentiere weiter mit den Features. Benutze falls notwendig eine oder mehrere der in der Vorlesung besprochenen Methoden für ungleichgewichtete Klassen.

Experimentiere mit Hyperparameter vom Modell. Ändere händisch einige Werte von Hyperparametern und untersuche, wie sich die Ergebnisse ändern. Erkläre die Ergebnisse. Danach, benutze Optuna für Bayes'sche Optimierung. Benutze TPESampler – das entspricht am besten der in der Vorlesung besprochenen Optimierung (Dokumentation und Beispiel). Erstelle zusätzlich Visualisierungen des Optimierungsprozesses. Benutze das, um Zwischenschritte zu speichern. Siehe ein alternatives vollständiges Beispiel hier.

Beschreibe alle Ergebnisse im Notebook. Versuche, Erklärungen zu finden. Markdown (Beispiele) erlaubt das einfache Integrieren von formatierten Texten, inkl. Gleichungen, Titel, Tabellen, Bulletpoints, usw. in Jupyter Notebooks.

Bonus × 1.5, × 1.0, × 0.5 für die drei Teams mit dem besten macro-f1

Bonus × 1.5: Implementiere und optimiere, für identisch aufgebaute Features, einen anderen boosted trees Algorithmus: lightgbm, adaboost, oder catboost. Erkläre, im Vergleich, die Aufbauweise der Bäume (mit Plots), den Lernprozess und die Ergebnisse.