GRUNDLAGEN DES MASCHINELLE LERNENS – L3

PRINCIPAL COMPONENT ANALYSIS UND K-MEANS CLUSTERING

Erhalten in L3

Abgabe in L4

Benutze das gereinigte Ames Housing Dataset, mit passendem encoding für die kategorischen Features und skaliere den Datensatz mit min-max scaling. Siehe auch hier und hier

Benutze PCA, um den Datensatz auf 98% der Varianz zu reduzieren. Wie viel von der Varianz des Datensatzes erklärt jede Principal component (siehe explained_variance_ratio_)? Mit wie vielen Features bleibt man? Wie viele Principal Components sind notwendig, wenn man 95%, 90%, bzw. 80% der Varianz behalten will? Zeichne die kumulative Varianz als Funktion der Anzahl von Principal Components.

Mit dem auf den vier oben erwähnten Schwellen der Varianz reduzierten Datensatz trainiere je ein k-Means Clustering Modell. Benutze die Ellenbogenmethode um die optimale Anzahl der Cluster zu finden. Zeichne das Plot. Zeichne Silhouettenplots für mehrere Anzahlen von Clusters. Erstelle auch ein scatter plot, wo die ersten 2 principal components als Punkte sichtbar sind. Färbe die Punkte unterschiedlich, je nach Cluster. Repräsentiere, mit einem anderen Symbol, auch die jeweiligen Zentroide. Gibt es Unterschiede? Erkläre. Benutze für die Skalierung der Daten sowohl min-max-Skalierung, als auch Normalisierung. Macht das Logarithmieren von Features (wo sinnvoll) einen Unterschied? Wie unterscheiden sich die Ergebnisse? Versuche, eine **Erklärung** zu finden.

Versuche den Einfluss der Features auf die wichtigsten principal components zu sehen. Benutze dafür `loadings = pca.components_.T * np.sqrt(pca.explained_variance_)`. Repräsentiere das grafisch.

Erkläre in eigenen Worten, welche Eigenschaften jedes Cluster hat, z.B. im Cluster X findet man tendenziell Häuser mit den Eigenschaften a, b, und c. Benutze, z.B. Visualisierungen aus Aufgabe 1.

Gib dem Modell einige ihm unbekannte Datenpunkte. Erfinde selbst ein paar plausible Häuser. Welchem Cluster werden sie zugeordnet? Ist es, intuitiv, richtig oder falsch? Erkläre. Hinweis: vor der Inferenz muss man den Datenpunkt mithilfe vom PCA transformieren – warum?

Bonus:

a. Zeichne **interaktive** 3D Scatter Plots (zoomen und rotieren) mit den ersten 3 principal components, verschieden gefärbt, für jedes Clustering. Zeichne, mit einem anderen Symbol, auch die jeweiligen Zentroide. Was für zusätzliche Patterns kann man lesen? Wie interpretiert man die Ergebnisse? Ist k-means für diese Daten passend, oder soll man eine andere Clusteringmethode benutzen? Warum?
b. Erstelle ein zweites, gleiches Plot. Färbe dabei die Punkte nach den sechs in der vorherigen Laboraufgabe definierten Preiskategorien, z.B. die teuerste Klasse mit blau, die zweitteuerste mit grün, usw. Was bemerkst du? Vergleiche die Klassifikation nach den Preisklassen mit den jetzt

gefundenen optimalen Clustern. Erkläre. Hinweis: denke auch an die feature importance und die Zusammensetzung der principal components.